

DERİN ÖĞRENMENİN TEMELLERİ

Garbage Classification

ZEYNEP PALABIYIK
220202016

SENA KÖSEOĞLU
220202042

Makale Özetleri:

1. **Nasien, Adiya, Farkhan, Rahmadhani ve Samah (2025) Automated Waste Classification Using YOLOv11: A Deep Learning Approach for Sustainable Recycling:** Bu çalışma, atık sınıflandırma sorununa çözüm olarak derin öğrenme tabanlı otomatik bir sistem önermektedir. Roboflow Universe platformundan alınan 10.464 görsellik özel bir veri seti üzerinde eğitilen modelde, en güncel YOLO mimarisi olan YOLOv11 kullanılmıştır. Performansı mAP, Kesinlik (Precision) ve Doğruluk (Accuracy) metrikleriyle ölçülen model, test verisi üzerinde %94 **genel doğruluk** elde etmiştir. Çalışma, modelin genel başarısının yüksek olduğunu, ancak şeffaf plastik ve cam materyalleri ayırt etmekte zorlandığını ortaya koymuştur.
2. **Li, Lingbo, et al. (2025) Enhanced ResNet-50 for Garbage Classification:** Mevcut modellerin yavaşlık ve düşük doğruluk sorunlarını çözmeyi hedefleyen bu çalışmada, TrashNet (2.527 resim) veri seti kullanılmıştır. Standart ResNet-50 mimarisi, "Gereksiz Ağırlıklı Özellik Birleştirme Modülü" ve "Derinlemesine Ayrılabilir Konvolüsyonlar" gibi yeniliklerle geliştirilmiş ve "Ağırlıklandırılmış Odak Kaybı" fonksiyonu kullanılmıştır. Model, TrashNet veri setinde %94.13 doğruluk oranına ulaşarak, orijinal ResNet-50'den (%84.52) çok daha başarılı, daha az parametrelili ve daha hızlı sonuçlar üretmiştir.
3. **Bright, Tyrone, Sarp Adali, and Cristina Trois. Systemic Review and Meta-Analysis: AI-Powered Drone Technology... (2025):** Bu çalışma, yapay zeka destekli drone'ların atık yönetiminde kullanımını inceleyen kapsamlı bir meta-analizdir. TACO, SWAD ve VAV-Vaste gibi veri setlerini kullanan 21 akademik çalışmayı sentezleyen makale, YOLO ve Faster R-CNN gibi modelleri kıyaslamıştır. Analiz sonucunda, geleceğe yönelik en etkili çözüm olarak Çok Spektrumlu (Multispectral) verileri işleyebilen hibrit bir YOLO-Transformer modeli önerilmiştir. İncelenen çalışmaların birleştirilmiş F1 skoru %85.9 olarak hesaplanmıştır.
4. **Qiu, Xie ve Huang (2025) An Improved EfficientNetV2 for Garbage Classification:** Bu makale, veri toplama maliyeti ve gerçek zamanlı performans zorluklarını aşmak için EfficientNetV2 tabanlı "CE-EfficientNetV2" modelini önermektedir. Modele, özellik kaybını azaltan "Kanal Verimli Dikkat (CE-Attention)" ve karmaşıklığı düşüren "Hafif Çok Ölçekli Uzaysal Özellik Çıkarma (DP-SAFM)" modülleri eklenmiştir. Huawei Cloud (~15.000 resim) ve TrashNet veri setlerinde yapılan deneylerde model, sırasıyla %95.4 ve %96.5 doğruluk elde ederek MobileNetV4 ve RepViT gibi rakiplerini geride bırakmıştır.
5. **Akhila vd. (2025) Garbage Classification Using CNN:** Manuel ayıklamanın verimsizliğini ele alan bu araştırma, 5 sınıflı (Plastik, Kağıt, Metal, Cam, Organik) özel bir atık veri seti kullanmıştır. Sistem, ImageNet üzerinde önceden eğitilmiş bir VGG16 mimarisinin "ince ayar" (fine-tuning) yapılmasıyla oluşturulmuş ve Flask tabanlı bir web arayüzü ile uygulanmıştır. Model, %88 doğruluk doğruluğuna (Validation Accuracy) ulaşarak gerçek dünya uygulamaları için potansiyel göstermiştir.
6. **Madhavi vd. (2025) SwinConvNeXt: A Fused Deep Learning Architecture:** Görsel olarak benzer atıkların sınıflandırılmasındaki zorlukları aşmak için Swin Transformer ve ConvNeXt yapılarının birleştirildiği "SwinConvNeXt" mimarisi önerilmiştir. Kaggle Garbage Classification veri seti üzerinde test edilen model; küresel özellikleri Swin Transformer, yerel özellikleri ise ConvNeXt bloğu ile çıkarmaktadır. Model, %98.97 doğruluk, %98.42 kesinlik ve %98.61 duyarlılık elde ederek ResNet50V2 gibi modellerden daha hafif ve verimli olduğunu kanıtlamıştır.
7. **Yang, Yuhang, et al. Dynamic Graph Neural Network for Garbage Classification (2025):** Bu çalışma, çok modlu özellik füzyonuna (anlamsal + renk) dayalı dinamik bir graf sinir ağı (GNN) yaklaşımı sunmaktadır. Özel KRHO (9.122 görüntü) ve TrashNet veri setleri kullanılmıştır. Önerilen mimari, RNAM modülünden anlamsal özellikleri ve LAB renk histogramlarından renk özelliklerini alarak dinamik bir Graf

Dikkat Ağı (GATv2Conv) ile işler. Model, KRHO veri setinde %99.33, TrashNet'te ise %99.49 gibi olağanüstü yüksek doğruluk oranlarına ulaşmıştır.

8. **Ghosh, Debojyoti, Soumya K. Ghosh, and Adrijit Goswami. Neuroplastic Modular Framework (2025):** Bu makale, "Nöroplastik Modüler Sınıflandırıcı" adlı hibrit bir mimari sunmaktadır. 10 sınıflı düzenlenmiş bir veri seti kullanan model, yerel özellikler için ResNet-50, küresel bağlam için Vision Transformer (ViT) ve hafıza desteği için FAISS tabanlı benzerlik erişimini birleştirir. Modelin eğitim sırasında dinamik olarak büyüyen "nöroplastik" yapısı, test setinde %97.15 doğruluk sağlayarak ResNet152 (%92.93) gibi statik modelleri geçmiştir.
9. **Jin, Shoufeng, et al. Deep Learning Enabled Garbage Classification for Aerial Images (2025):** Havadan çekilen atık görüntüsü eksikliğini gidermek için 7 sınıflı "KACHARA" (4.727 görüntü) veri seti tanıtılmıştır. Transfer öğrenme tekniğiyle (son 5 katmanı eğitilen) MobileNetV3-Large modeli kullanılmıştır. Model, %94.37 genel doğruluk ve %94.22 F1 skoru elde etmiş; aynı zamanda 21.3 MB boyutuyla test edilen en verimli model olmuştur.
10. **Arishi, Ali. Real-Time Household Waste Detection (2025):** Bu çalışma, YOLOv8 tabanlı gerçek zamanlı bir atık tespit sistemi sunar. 17 atık türünü kapsayan özel bir veri seti üzerinde çalışan sistemde, YOLOv8 modeline CBAM ve SE dikkat mekanizmaları eklenmiştir. En başarılı sonucu veren YOLOv8-CBAM modeli, veri zenginleştirme ile birlikte %89.5 mAP değerine ulaşarak temel modelden %4.2 daha iyi performans göstermiştir.
11. **Sayem vd. (2025) - "Enhancing Waste Sorting and Recycling Efficiency":** Endüstriyel atık tesisleri için WaRP Dataset (10.406 görüntü, 28 sınıf) kullanılarak iki model önerilmiştir. Sınıflandırma için DenseNet-201 ve MaxViT'i birleştiren 2S_DenseViT modeli %83.11 doğruluk ile sınıfının en iyisi olurken; nesne tespiti için kullanılan GELAN-E modeli %63 mAP50 skoruyla diğer YOLO modellerini geride bırakmıştır.
12. **Singh, R., et al. "Performance analysis of garbage classification using balanced and unbalanced dataset with EfficientNetV2B1 architecture."(2024) :** Singh vd. (2024) tarafından yapılan "Performance Analysis of Garbage Classification Using Balanced and Unbalanced Dataset with EfficientNet V2B1 Architecture" başlıklı çalışmada, derin öğrenme tabanlı EfficientNetV2B1 mimarisinin atık sınıflandırma performansı, dengeli ve dengesiz veri setleri üzerinde karşılaştırmalı olarak incelenmiştir. Toplam 12 atık sınıfını içeren çalışmada, 15.515 görüntüden oluşan dengesiz veri seti ve 7.260 görüntüden oluşan dengeli veri seti ayrı ayrı eğitilmiştir. Deneysel sonuçlar, dengesiz veri setinin %95.22 doğruluk oranı ile %91.46 doğruluk elde eden dengeli veri setinden daha üstün performans gösterdiğini ortaya koymuştur. Çalışma, EfficientNetV2B1 modelinin sınıf dağılımındaki dengesizliklere rağmen yüksek veri hacmiyle beslendiğinde %99.98 AUC skoruna ulaşarak olağanüstü bir ayırt etme yeteneğine ve kararlılığa sahip olduğunu kanıtlamıştır.
13. **Wang vd. (2024) - "GFN: A Garbage Classification Fusion Network":** ResNet (yerel) ve Vision Transformer (global) mimarilerini CBAM ve PPM dikkat mekanizmalarıyla birleştiren hibrit GFN modeli sunulmuştur. Model, zorlu Garbage Dataset üzerinde %96.54, TrashNet üzerinde ise %94.21 doğruluk elde ederek dengesiz veri setlerinde yüksek başarı göstermiştir.
14. **Wang, Zhaoqi, Wenxue Zhou, and Yanmei Li. Application Research of Image Classification (2024):** Bu çalışma, Capuchin Arama Algoritması (CapSA) ile optimize edilmiş bir CNN ve Hata Düzeltici Çıktı Kodları (ECOC) tabanlı hibrit bir sınıflandırıcı önermektedir. TrashNet ve HGCD (12 sınıf) veri setlerinde test edilen yöntem, sırasıyla %98.81 ve %99.01 doğruluk oranlarına ulaşarak optimizasyonun etkisini kanıtlamıştır.
15. **Ahmed Khan vd. "Enhancing Trash Classification using Federated Learning"(2024):** Akıllı şehirler için TrashBox Dataset (~17.000 görsel) üzerinde 10 farklı CNN modeli test edilmiştir. ResNeXt-101 modeli, %89.62 doğruluk ve %89.66 F1 skoru ile en başarılı model olarak belirlenmiş ve bu modellerin veriyi paylaşmadan eğitilebilmesi için "Federated Learning" (Dağıtık Öğrenme) yapısı önerilmiştir.
16. **Kanani, Jenil. Image Recognition Based on Pixel Distribution Learning (2024):** Standart CNN'lerin şekil yerine dokuya odaklanmasını sağlamak için görüntüleri karıştırılmış parçalarla (shuffled patches) eğiten bir yöntem önerilmiştir. Kaggle Garbage Classification veri setinde, bu yöntemle eğitilen küçük bir CNN modeli %82.4 doğruluk başarıları elde ederek, orijinal görüntülerle eğitilen modelden (%76.0) daha başarılı olmuştur.
17. **Salur, Mehmet Umut, et al. Derin Öğrenme ile Akıllı Çöp Konteyneri Tasarımı (2024):** Akıllı bir çöp konteyneri prototipi için Kaggle veri setinin 4 sınıfı (Cam, Metal, Kağıt, Plastik) üzerinde transfer öğrenme uygulanmıştır. Test edilen 5 model arasından DenseNet169, %95.22 doğruluk oranıyla en başarılı model olmuş ve prototip sisteme entegre edilmiştir.
18. **Yıldız, E. N., Bingöl, H., & Yıldırım, M. Önerilen Hibrit Model ile Çevresel Atıkların Sınıflandırılması (2023):** Kaggle veri seti üzerinde sadece derin öğrenme modelleri ile hibrit modeller karşılaştırılmıştır. DenseNet201'in özellik çıkarıcı olarak kullanıldığı ve sınıflandırmanın Destek Vektör

Makineleri (DVM) ile yapıldığı hibrit model, %89.70 doğruluk ile tek başına çalışan DenseNet201'den (%85.94) daha başarılı bulunmuştur.

19. **Pavithra vd. (2023) – Garbage Collection and Identification System:** Pavithra vd. (2023), atık tanıma ve sınıflandırma problemini çözmek amacıyla CNN tabanlı DenseNet121 modelini kullanan bir akıllı atık yönetim sistemi önermiştir. Çalışmada, 2527 görüntü ve 6 sınıftan oluşan TrashNet veri seti üzerinde DenseNet121'in performansı değerlendirilmiş; ayrıca modelin fully connected katmanları Genetik Algoritma (GA) ile optimize edilerek sınıflandırma doğruluğunun artırılması hedeflenmiştir. Önerilen yaklaşım, derin öğrenme, IoT ve ödül-temelli atık toplama mekanizmasını birleştirerek sürdürülebilir ve teşvik edici bir atık yönetim modeli sunmaktadır.
20. **Sürücü, Selim, and İrem Nur Ecemiş. Garbage Classification Using Pre-Trained Models (2022):** Kaggle veri setinde (6 sınıf) transfer öğrenimi ile 5 farklı mimari test edilmiştir. **InceptionV3** modeli, %94.69 doğruluk ve 0.8277 Cohen Kappa skoru ile en başarılı model olmuştur. **EfficientNetB7** ve **ResNet50** modelleri ise bu çalışmadaki konfigürasyonla atıkları ayırt etmede başarısız olmuşlardır.

1 . Özet

Günümüzde hızla artan kentleşme ve tüketim alışkanlıkları, atık yönetimini küresel bir sorun haline getirmiştir. Atıkların kaynağında doğru sınıflandırılması, geri dönüşüm süreçlerinin verimliliği için kritik öneme sahiptir. Bu çalışmada, çevresel atıkları türlerine göre sınıflandırmak amacıyla derin öğrenme tabanlı bir sistem geliştirilmiştir. Çalışmada Trashbox ve Garbage Dataset veri setleri birleştirilerek dengeli bir veri kümesi oluşturulmuştur. Elde edilen veri seti üzerinde **DenseNet-201** ve **EfficientNetV2** mimarilerinin performansları karşılaştırılmıştır. Ayrıca eğitim sürecinde farklı optimizasyon algoritmaları ve kayıp fonksiyonlarının etkileri incelenmiştir.

Anahtar Kelimeler: Atık Sınıflandırma, Derin Öğrenme, DenseNet-201, EfficientNetV2 Görüntü İşleme, Geri Dönüşüm, Sürdürülebilirlik.

2. Giriş.

Günümüzde hızlı kentleşme, artan tüketim oranları ve yetersiz atık yönetim sistemleri, çevre kirliliğini küresel bir sorun haline getirmiştir. Atıkların doğru şekilde sınıflandırılması, geri dönüşüm oranlarının artırılması ve sürdürülebilir şehirlerin inşası açısından kritik öneme sahiptir. Ancak, geleneksel atık ayrıştırma yöntemleri manuel iş gücüne dayanmakta, bu da süreci hem yavaş hem de hataya açık hale getirmektedir [2, 3]. Bu nedenle, derin öğrenme tabanlı çözümler, atık sınıflandırma problemini otomatik, hızlı ve yüksek doğrulukla çözebilmek için önemli bir araştırma alanı olarak öne çıkmaktadır.

3. Literatür Taraması

Son yıllarda yapılan çalışmalar, konvolüsyonel sinir ağlarının (CNN) atık sınıflandırmasında insan performansına yakın ve daha hızlı sonuçlar üretebildiğini göstermiştir. Örneğin, **DenseNet-201** 'in farklı mimarilerinin birleştirildiği veri setinde %83.11 doğrulukla başarılı sonuçlar elde etmiştir [1]. Bu literatür taraması sonucunda, çalışmada **DenseNet-201** ve **EfficientNetV2** mimarilerinin performanslarını karşılaştırarak, çevresel atıkların otomatik sınıflandırılması hedeflenmiştir. Model eğitimi ve değerlendirmesi için iki geniş kapsamlı veri seti kullanılmıştır: **TrashBox** ve **Garbage Dataset**, derin öğrenme tabanlı sınıflandırmalar için güçlü bir temel sunmaktadır [4][5].

Ayrıca, verimlilik odaklı güncel çalışmalarda EfficientNet ailesi öne çıkmaktadır. Qiu ve ark. (2025), EfficientNetV2 mimarisini temel alarak geliştirdikleri model ile TrashNet veri setinde %96.5 gibi yüksek bir başarı oranı yakalamış ve modelin atık sınıflandırma görevlerindeki etkinliğini kanıtlamıştır [6].

Bu kapsamda, çalışmanın temel amacı farklı mimarilerin (DenseNet-201, EfficientNetV2) aynı veri setleri üzerinde performanslarını karşılaştırarak, **en yüksek doğruluk-verimlilik dengesini** sağlayan yapıyı belirlemektir.

4. Yöntem

4.1. Kullandığımız Veri Setleri

Bu projede, atık sınıflandırma konusunda "Trashbox" ve "Garbage Dataset" isimli iki farklı veri setini temel aldık. Sadece bir tanesini kullanmak yerine, bu iki veri setini birleştirerek **merged_dataset2** (birleştirilmiş veri seti) adını verdiğimiz daha büyük ve daha zengin bir veri seti oluşturduk.



şekil-1

(glass , metal, paper, plastic, clothes, cardboard)

Modelimizi düzgün bir şekilde eğitmek ve ne kadar başarılı olduğunu adil bir şekilde ölçmek için bu veri setini üç parçaya böldük:

1. **%80 Eğitim (Train) Seti:** Modelin öğrenmesi için kullanılacak en büyük parça. **18,600 civarı görüntü**
2. **%10 Doğrulama (Validation) Seti:** Modelin eğitimi devam ederken ne kadar iyi gittiğini kontrol etmek için kullandığımız ara-test seti. **3200 civarı görüntü**
3. **%10 Test Seti:** Eğitim tamamen bittikten sonra, modelin daha önce hiç görmediği fotoğraflar karşısındaki gerçek başarısını görmek için kullandığımız set. **3200 civarı görüntü**

toplam 25,100 civarı görüntü

4.2. Verileri Modele Hazırlama (Ön İşleme)

Bilgisayardan gelen ham fotoğrafları doğrudan derin öğrenme modeline veremeyeceğimiz için ön hazırlık yaptık.

Yeniden Boyutlandırma ve Formatlama: Veri setimizdeki fotoğraflar farklı boyutlardaydı ama modellerin hepsi aynı boyutta fotoğraf bekler. Bu yüzden, tüm fotoğrafları eğitim sırasında standart 224x224 piksel boyutuna getirdik.

5. Model Mimarisi

Model Mimarileri Bu çalışmada, literatürdeki başarıları kanıtlanmış üç farklı CNN mimarisi kullanılmıştır:


1- DenseNet-201: Katmanlar arası bilgi akışını maksimize eden ve özellik tekrarını kullanan yoğun bağlantılı (dense connection) bir yapıdır.

DenseNet, konvolüsyonel sinir ağlarının performansını artırmak için katmanlar arasında yoğun bağlantı kullanan güçlü bir derin öğrenme mimarisidir. Bu gelişmiş mimari, görüntü sınıflandırması, nesne algılama ve segmentasyon gibi çok çeşitli bilgisayar görme görevlerinde önemli verimlilik göstermiştir. [7] Versiyonlarda belirtilen sayılar modellerin ağında bulunan katman sayısını ifade etmektedir. Wang ve

Zhang (2020) tarafından, önceden eğitilmiş popüler CNN modellerin karşılaştırma sonuçlarına dayanarak DenseNet'in diğer modellere göre daha başarılı olduğu bildirilmiştir. [8]

DenseNet-201, 224x224x3 görüntü giriş boyutuna sahiptir. İlk 224 değeri genişliği, sonraki 224 değeri yüksekliği ve 3 değeri derinliği (renk kanalları sayısını) ifade eder. Çalışmada veri setinden derin öz nitelikleri elde etmek için ağın sonunda bulunan tam bağlantılı katmandan önce gelen küresel ortalama havuzlama katmanı "Global Average Pooling" (GAP) üzerindeki aktivasyonlar kullanılmıştır. GAP, toplamda 1920 özellik sağlamıştır.[8] DenseNet-201'in genel mimarisi Şekil 3 üzerinde gösterilmiştir.

Bu çalışmada DenseNet-201 mimarisinin özgün yapısı korunmuştur. Model, ImageNet veri kümesi üzerinde önceden eğitilmiş ağırlıklar kullanılarak transfer öğrenme yaklaşımı ile uygulanmıştır. DenseNet-201'in Dense Block ve Transition Layer bileşenlerinde herhangi bir yapısal değişiklik yapılmamış, yalnızca modelin son sınıflandırma katmanı problemdeki sınıf sayısına uygun olacak şekilde yeniden düzenlenmiştir.




şekil-2

2- DenseNet-121:

DenseNet-121, DenseNet mimarisinin daha hafif ve hesaplama açısından daha verimli bir versiyonu olup, katmanlar arası yoğun bağlantı yapısını koruyarak daha az parametre ile yüksek performans sunmayı amaçlamaktadır. Bu mimaride her katman, kendisinden önce gelen tüm katmanların özellik haritalarını girdi olarak alarak bilgi akışını güçlendirmekte ve gradyan kaybolması problemi azaltmaktadır. DenseNet121 modeli, görüntüler arasındaki özellik aktarımını güçlendiren yoğun bağlantı yapısı sayesinde atık tanıma problemlerinde etkili sonuçlar sunmaktadır. CNN tabanlı modellerin, özellikle DenseNet121 mimarisinin, çöp türlerinin otomatik tanımlanmasında endüstri standardı haline geldiği görülmektedir.[10]

Bu çalışmada DenseNet-121 modeli, ImageNet veri kümesi üzerinde önceden eğitilmiş ağırlıklar kullanılarak transfer öğrenme yaklaşımı ile uygulanmıştır. Modelin Dense Block ve Transition Layer yapıları korunmuş, yalnızca ağın sonundaki tam bağlantılı sınıflandırma katmanı problemdeki sınıf sayısına uygun olacak şekilde yeniden düzenlenmiştir. Böylece modelin önceden öğrenilmiş genel görsel öz niteliklerinden faydalanılarak, atık türlerinin daha etkin bir şekilde sınıflandırılması

hedeflenmiştir. DenseNet-121'in, DenseNet-201'e kıyasla daha az parametre içermesi sayesinde **aşırı öğrenme (overfitting) riskinin azaltılmasına** katkı sağladığı gözlemlenmiştir. Bu yönüyle DenseNet-121, çalışma kapsamında karşılaştırmalı analizler için uygun ve güçlü bir alternatif model olarak değerlendirilmiştir.




şekil-3

3- EfficientNetV2:

EfficientNetV2, önceki nesil modellere kıyasla daha hızlı eğitim süresi ve parametre verimliliği sunmak amacıyla geliştirilmiş, özellikle Fused-MBConv (Birleştirilmiş Mobil Ters Şişe Boynu) bloklarını kullanarak işlem yükünü optimize eden gelişmiş bir konvolüsyonel sinir ağı mimarisidir. Bu mimari, görsel verilerdeki karmaşık desenleri daha az hesaplama maliyetiyle öğrenebilmekte ve aşamalı öğrenme (progressive learning) stratejisi sayesinde görüntü boyutuyla orantılı regülerizasyon uygulayarak doğruluk oranını artırmaktadır. Qiu vd. [6] tarafından yapılan çalışmalarda da vurgulandığı üzere, EfficientNetV2 mimarisi, atık sınıflandırma gibi yüksek ayırt edicilik gerektiren problemlerde sunduğu hızlı yakınsama ve güçlü özellik çıkarımı yetenekleriyle literatürde öne çıkmaktadır.

Bu çalışmada EfficientNetV2-Small modeli, ImageNet veri kümesi üzerinde önceden eğitilmiş ağırlıklar kullanılarak Transfer Öğrenme yaklaşımı ile modele entegre edilmiştir. Qiu vd. [6]'nin önerdiği iyileştirilmiş yapı referans alınarak, modelin özellik çıkarıcı omurgası (backbone) korunmuş, ancak sınıflandırma katmanı problemdeki atık türü sayısına göre yeniden kurgulanmıştır. Modelin genelleme yeteneğini artırmak ve aşırı öğrenme (overfitting) riskini minimize etmek amacıyla, sınıflandırıcı bloğuna Batch Normalization ve yüksek oranlı Dropout katmanları eklenmiştir. Bu sayede, EfficientNetV2'nin hem eğitim verisindeki ince detayları yakalaması hem de görülmeyen test verileri üzerinde kararlı bir sınıflandırma performansı sergilemesi hedeflenmiştir.



şekil-4

6. Deneysel Sonular ve Karşılařtırma

DenseNet-201, **DenseNet-121** ve **EfficientNetV2-S** mimarileri karşılařtırılmıřtır. Modeller; doęruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-skoru metrikleri üzerinden deęerlendirilmiřtir. Deneylerde farklı optimizasyon ve loss stratejilerinin ařırı ęrenme (overfitting) zerindeki etkileri analiz edilmiřtir.

DenseNet-201 modeli, Adam/AdamW optimizasyonu ile hem Cross Entropy hem de Focal Loss fonksiyonları kullanılarak eęitilmiřtir. Test sonuları incelendięinde, modelin genel doęruluk oranının %95–96 aralıęında olduęu grlmektedir. Ancak eęitim kaybı hızla dřerken doęrulama kaybının artıř eęiliminde olması, modelin veriyi ezberledięini ve overfitting problemi yařadıęını gstermektedir.

DenseNet-121 mimarisi, daha hafif bir yapı sunması nedeniyle Dropout ($p=0.5$) ve Weight Decay (L_2 regularization) ile desteklenmiřtir. Backbone katmanlarının dondurulması ve Focal Loss kullanımı sayesinde eęitim ve doęrulama kayıpları daha paralel ilerlemiřtir. Bu modelde doęruluk oranı %90 seviyelerine gerilese de, ařırı ęrenme belirgin biimde azalmıř ve daha dengeli bir genelleme performansı elde edilmiřtir.

EfficientNetV2-S modeli, transfer ęrenme kapsamında farklı dzenleme seviyeleriyle deęerlendirilmiřtir. İlk ařamada Adam optimizasyonu ve Cross Entropy Loss ile %96 doęruluk elde edilmiřtir. Ancak eęitim kaybı dřerken doęrulama kaybının artması, modelde overfitting olduęunu gstermiřtir.

Dzenleme (Dropout ve Weight Decay) eklendięinde doęrulama kaybındaki dalgalanmalar azalmıřtır. Final ařamada backbone katmanları dondurulmuř, Batch Normalization ve yksek Dropout ($p=0.6$) uygulanmıřtır. Bu yapı ile eęitim ve doęrulama kayıpları paralel ilerlemiř, overfitting giderilmiřtir. Model ezberden arındırılmıř ve gerek bir genelleme performansı sunmuřtur.

MODEL	ACCURACY	PRECISION	RECALL	F1-SCORE
DenseNet-201	0.95–0.96	0.94	0.94	0.94
DenseNet-121	0.90	0.88	0.89	0.89
EfficientNetV2	0.91	0.90	0.90	0.90

7. Sonu

Bu alıřmada, evresel atıkların otomatik olarak sınıflandırılması amacıyla derin ęrenme tabanlı  farklı mimari (DenseNet-201, DenseNet-121 ve EfficientNetV2-S) karşılařtırmalı olarak incelenmiřtir. TrashBox ve Garbage Dataset veri setlerinin birleřtirilmesiyle oluřturulan geniř ve dengeli bir veri kmesi zerinde, kapsamlı deneyler gerekleřtirilmiřtir.

Deneysel sonular, yksek doęruluk oranlarının tek bařına model bařarısını ifade etmede yeterli olmadıęını gstermiřtir. DenseNet-201, yksek doęruluk deęerlerine (%95–96) ulařsa da, eęitim ve doęrulama kayıpları arasındaki farklar, bu modellerde ařırı ęrenme (overfitting) eęiliminin bulunduęunu

ortaya koymuřtur. DenseNet-121 mimarisi ise daha dūřuk doęruluk deęerine (%90) sahip olmasına raęmen, daha dengeli ve kararlı bir genelleme performansı sergilemiřtir.

EfficientNetV2-S üzerinde uygulanan katman dondurma, Batch Normalization ve yüksek Dropout ieren optimize edilmiř mimari sayesinde overfitting problemi b y k  l de giderilmiř ve model, %91 doęruluk ile gereki ve g venilir bir performans sunmuřtur. Bu yapı, ezberden arındırılmıř olması nedeniyle gerek d nya atık sınıflandırma senaryoları iin daha uygun bir  z m olarak deęerlendirilmiřtir. Elde edilen sonular, akıllı geri d n ř m sistemleri ve s rd r lebilir evre uygulamaları iin derin  ęrenme tabanlı  z mlerin etkinlięini aıka g stermektedir.

8. Kaynaka

- [1] SAYEM, Faizul Rakib, et al. Enhancing waste sorting and recycling efficiency: robust deep learning-based approach for classification and detection. *Neural Computing and Applications*, 2025, 37(6): 4567–4583.
- [2] Li, Lingbo, et al. "Enhanced ResNet-50 for garbage classification: Feature fusion and depth-separable convolutions." *PloS one* 20.1 (2025): e0317999.
- [3] Akhila, Barupati, et al. "Garbage Classification Using Convolutional Neural Networks." *No, it has never appeared or been accepted by any conference or journal*. 2025.
- [4] Wang, Zhaoqi, Wenxue Zhou, and Yanmei Li. "GFN: a garbage classification fusion network incorporating multiple attention mechanisms." *Electronics* 14.1 (2024): 75.
- [5] Ahmed Khan, Haroon, et al. "Enhancing trash classification in smart cities using federated deep learning." *Scientific Reports* 14.1 (2024): 11816.
- [6] Qiu, W., Xie, C., and Huang, J. "An Improved EfficientNetV2 for Garbage Classification." *Advanced Intelligent Computing Technology and Applications*. Springer, 2025: 79-90.
- [7] <https://medium.com/nocoding-ai/densenet121-760df192f12d>
- [8] HAYIT, Tolga, and G kalp INARER. "X-RAY G R NT LER N  KULLANARAK GLCM VE DER N  ZN TEL KLER N B RLEř M NE DAYALI COVID-19 SINIFLANDIRILMASI." *Journal of Inonu University Health Services Vocational School/In n   niversitesi Saęlık Hizmetleri Meslek Y ksekokulu Dergisi* 10.1 (2022).
- [9] Singh, R., et al. "Performance analysis of garbage classification using balanced and unbalanced dataset with EfficientNetV2B1 architecture." *Journal of Computer Science* 20.10 (2024): 1310-1321.
- [10] Pavithra, S., et al. "Garbage Collection and Identification System." *Journal of Advancement in Parallel Computing* 6.3.